

Conclusion and perspectives

- Bilan des apports de la thèse.
 - **Objectif:** Dans cette thèse, nous nous sommes intéressés à l'apprentissage de métriques combinées multi-modal et multi-échelle en vue d'une classification kNN robuste.
 - **Uni-modal:** Les données temporelles, contrairement aux données statiques, peuvent être comparés non seulement sur la base de modalités comme les valeurs mais aussi au moins, sans être exhaustifs sur la base de modalités temporelles comme la forme ou la fréquence. De manière classique, la comparaison de séries se fait sur la base d'une modalité à l'échelle globale qui définit les mesures de distance habituellement utilisées (distance euclidienne, corrélation temporelle, distance à base Fourier, etc.).
 - **Multi-modal:** Afin de tenir compte de plusieurs modalités au sein d'une même métrique, certains auteurs ont proposés de combinés plusieurs modalités via des fonctions de combinaisons. Elles sont en général limités à 2 modalités et sont définis sans considération du classifieur. La recherche des meilleurs paramètres peut devenir lourd computationnellement en augmentant le nombre de métriques impliqués dans la combinaison.
 - **Multi-échelle:** Ce travail a mis en évidence l'importance de comparer les séries temporelles à différentes échelles temporelles. Les modalités et métriques cités précédemment peuvent être adaptées afin de comparer les séries, non seulement sur la base de l'échelle globale (impliquant l'ensemble des éléments de la série temporelle) mais aussi à une échelle plus localisées (impliquant une partie des éléments de la séries temporelles).
 - **Metric Learning:** Afin d'améliorer les performances d'un classifieur kNN, certains travaux dans la littérature se sont intéressés à l'apprentissage de la métrique en vue d'une classification robuste kNN. Ces approches reposent en général sur l'apprentissage d'une distance de Mahalanobis dans un cadre linéaire ou non-linéaire. Certains parallèles avec les SVM ont aussi été étudiés. Les travaux sont nombreux pour les données statiques, moins nombreux pour les données structurées, et en particulier encore dans ses début pour les séries temporelles.
 - **Formalisation:** La seconde partie de ce travail a abouti à la formalisation du problème d'apprentissage métriques combinées multi-modal et multi-échelle en vue d'une classification kNN robuste.
 - **Espace des paires:** Le calcul d'une métrique impliquant toujours deux éléments, nous avons proposé de représenter les paires de séries temporelles dans un espace de dissimilarités où chaque dimension est une métrique temporelle de base (i.e., une modalité à une échelle temporelle). L'apprentissage d'une métrique combinée de plusieurs métriques temporelle de base se ramène alors à l'apprentissage d'une

fonction dans l'espace de dissimilarités qui vérifie au moins les propriétés d'une dissimilarité (positivité, réflexivité, symétrie). Rappelons que l'interprétation de proximité dans cet espace sur la proximité des séries dans l'espace d'origine doit être fait avec prudence.

- **m2tml optimisation:** le problème d'apprentissage de la métrique combinées peut être de manière général ramené à un problème d'apprentissage de métrique. Il est formalisé sous la forme d'un problème d'optimisation impliquant 3 termes: 1) un terme de régularisation dont le but est de rapprocher les paires pull (similaires). 2) un terme loss dont le but est d'éloigner les paires push (dissimilaires). 3) des contraintes liés aux paires dissimilaires. Plusieurs stratégies pour construire les ensembles pull et push ont été proposés. La solution retenue est celle des mNN+ vs mNN-. Nous pensons qu'en élargissant en apprentissage le voisinage au m plus proche permettra de mieux généraliser la métrique lors du test.
- **Les différentes formalisations:** Depuis le problème général, nous avons proposé 3 formalisations impliquant différentes régularisations ou frameworks: linéaire, quadratic, basé svm. Dans la formalisation linéaire, le terme de régularisation est linéaire et la métrique combinée est une combinaison linéaire des métriques de bases, vérifiant les propriétés d'une dissimilarité. Dans la formalisation quadratique, le terme de régularisation est quadratique. Similairement au développement svm, le problème peut être transformé sous une forme n'impliquant que des produits scalaires, permettant d'étendre l'apprentissage de la métrique combinée à des combinaisons à la fois linéaire comme non-linéaire via le kernel trick. La métrique apprise ne vérifie pas cependant les propriétés d'une dissimilarité (non-positive).
- **Solution basée svm:** Dans le framework basé svm, la fonction de distance n'est pas connue a priori. Le but est de construire un classifieur svm qui permet de séparer les ensembles pull et push. Sur la base de la solution obtenue du classifieur, une métrique est bâtie qui respecte les propriétés d'une métrique. En particulier, on souligne 2 éléments importants impliqués dans la métrique: la norme du projeté, la distance à la marge du projeté. La norme du projeté d'une paire permet de mesurer la proximité entre les séries temporelles impliquées dans la paire, d'après les features retenus pour séparer les classes pull et push. Afin d'assurer que la norme des paires push soit inférieurs à celles des paires pull, la distance du projeté à la marge nous permet de déterminer l'appartenance d'une paire à l'ensemble pull ou push. Le terme push est donné par une transformation exponentielle de la distance à la marge du projeté contrôlé par un paramètre qui mesure la force du terme push en fonction de la configuration des données. Grâce au framework svm, la méthode peut être naturellement étendu pour apprendre des fonctions non-linéaires.
- **Pre-processing lié au svm:** La solution svm retenue nous amène à des éléments de pré-processing nécessaire: normalisation de l'espace des dissimilarités, normalisation des voisinages.
- **Expérimentation:** L'efficacité de la méthode proposée m2tml a été vérifiée dans un vaste nombre de données publiques dans le cadre d'une classification 1NN de séries temporelles univariées. Les données considérées étaient de domaines divers,

de nombres de classes divers, avec des tailles de séries courtes et longues et un nombre divers de séries en apprentissage. Certaines de ces bases obtiennent des scores concluant avec les métriques valeurs classiques (euclidienne, dtw) et d'autres sont encore ouverts à des améliorations. La méthode proposée `m2tml` permet d'obtenir soit des scores équivalents aux métriques classiques globales, soit d'améliorer les résultats de la classification. Comparativement aux combinaisons a priori, la méthode atteint des performances similaires mais permet d'ajouter des métriques sans devoir ajouter de nouveaux paramètres à optimiser. Soulignons l'avantage supplémentaire de la méthode à interpréter les résultats obtenus: elle permet de localiser les modalités et localisations temporelles d'intérêt par apprentissage qui permet de purifier les voisinages. Ainsi, lorsque dans le cadre d'une utilisation industrielle, en l'absence de connaissance a priori sur les séries, la méthode permet de comprendre ce qui permet de discriminer au mieux les séries afin d'avoir des voisinages purifiées.

- Perspectives

- **Extension à d'autres modalités:** Le travail effectué s'est intéressé à 3 types de distance (distance euclidienne, corrélation temporelle, distance à base Fourier). Il existe cependant d'autres mesures de distance pour les séries temporelles qu'il serait intéressant d'étudier (wavelets, MFCC, etc.) (cf article).
- **Découpage multi-échelle:** Dans ce travail, nous avons proposé de découper les séries temporelles avec une architecture dichotomique mais d'autres solutions pourraient être proposées: par exemple une fenêtre glissement qui permettrait de localiser plus finement les événements d'intérêt (prendre l'exemple de SonyAIBO comme le suggère Sylvain).
- **Multi-pass learning:** le framework proposé souffre du même inconvénient que celui de Weinberger. La distance initiale est une norme 2 dans l'espace des paires. Elle permet de définir les voisinages pour la construction des ensembles pull et push qui reste fixe pendant le processus d'optimisation. Une autre solution serait de réitérer la distance apprise pour re-définir les ensembles pull et push et ré-apprendre de manière itérative la métrique jusqu'à convergence.
- **Autre proposition pour D :** La proposition de définition de la métrique D pourrait être élargie. Par exemple, on pourrait penser à une solution qui permet d'élargir à des lambdas négatifs. Inconvénient: avec un lambda négatif, la métrique aurait un effet pull et non push, qui risque de binariser la métrique en incluant des distances très proches de 0 pour les plus proches voisins. Or dans une classification kNN, la distance des plus proches voisins nous permet de faire la classification. En ramenant les distances des plus proches voisins, proches de 0, on a un risque de moins bien discriminer.
- **Extension au multivarié:** on pourrait facilement étendre le framework pour des séries temporelles multivariées. Pour chaque dimension de la série multivariée, on calcule les métriques de bases de chaque échelle qui deviennent de nouvelles dimensions basiques pour notre algorithme.
- **Extension à la régression:** Le travail pourrait être étendu à des problèmes de

régression. Le seul changement qui est impliqué est la définition du label y_{ij} lorsque le label y_i est une valeur continue et non une classe (cf la proposition).

- **Apprentissage locale de la métrique:** Dans le cadre du metric learning, des auteurs se sont intéressés à l'apprentissage de métrique localisés et non globales. On pourrait penser apprendre une métrique par localité (voisinage) et combinée l'ensemble des métriques locales en une métrique globale.
- **Utilisation de la distance apprise dans d'autres algorithmes:** Dans l'industrie, il est souvent important d'avoir un modèle interprétable. Des algorithmes comme les Arbres de décision apporte une représentation visuelle qui permet de comprendre aisément le modèle appris. Des travaux sur les arbres temporelles ont été effectués dans la littérature (cité papier ahame) utilisant les métriques classiques (euclidienne, corrélation). On pourrait s'inspirer de ces travaux pour construire un arbre avec la métrique apprise par m2tml.